1 А зачем мы тут

Известная сатирическая фраза "*Существуют три вида лжи: ложь, наглая ложь и статистика*", которую приписывают разным авторам, включая Бенджамина Дизраэли и Марка Твена, показывает, как можно манипулировать данными, чтобы создать ложное представление о реальности.

Информация: *с* 2025 *года минимальный размер оплаты труда (МРОТ) рассчитывается на основе* ***медианной*** *заработной платы*.

На рис. показана гистограмма доходов граждан России на основе официальных данных Росстата за 2023 год.

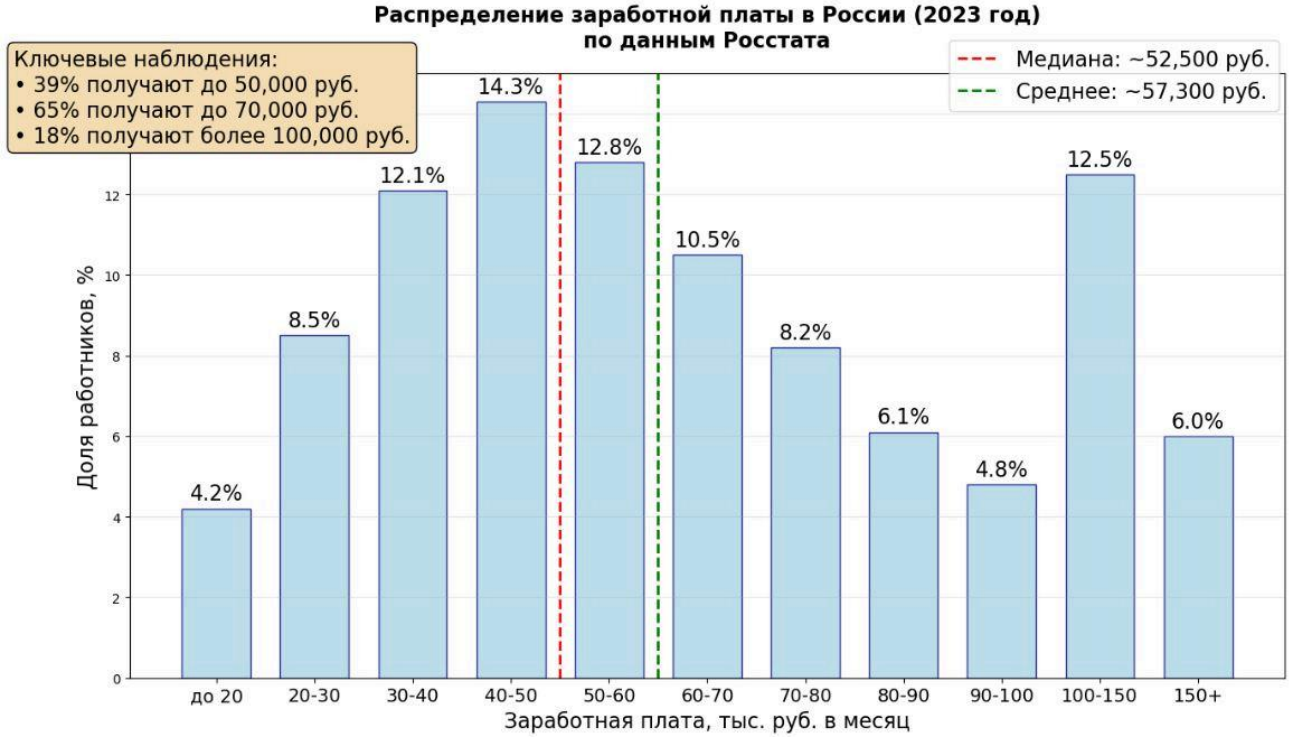


Рис. Распределение заработной платы в России (2023 год)

Использование среднего арифметического для анализа доходов сделало бы большинство действительно нуждающихся семей формально "благополучными" и лишило бы их поддержки (в виде льгот, пособий, выдачи бесплатного питания и лекарств и пр.), что неприемлемо с точки зрения социальной справедливости.

Так (по результатам многолетних наблюдений) официально признано, что в России:

- из-за влияния высокооплачиваемых групп медиана ниже среднего;
- модальное значение ниже медианного;
- распределение доходов сильно скошено вправо, поэтому основная масса населения сосредоточена в левой части графика кривой распределения.

Рассмотрим на примере, как одинаковое *среднее значение* может скрывать совершенно разную природу данных.

Предположим, что два бывших одноклассника (одногруппника), являющиеся руководителями компаний A и B, предлагают вам работу. При этом руководитель компании A сообщает, что в его организации средняя заработная плата составляет 122 у.е., а руководитель компании B, что у него – 122.5 у.е.

Можно ли по этим средним считать, что в компании B зарплата сотрудников немного больше? Ответ: ***нет***.

Пусть нам стали известны данные по зарплатам, по которым были вычислены указанные средние значения. Посмотрим на них более внимательно и вычислим рассмотренные выше *меры центральной тенденции*.

Компания A:

- **данные по зарплате** (в у.е.): $130, 125, 90, 135, 140, 110, 150, 180, 40, 120$;
- **количество значений**: 10;
- **среднее значение**:
$$\frac{130 + 125 + 90 + 135 + 140 + 110 + 150 + 180 + 40 + 120}{10} = 122;$$
- **медиана** (упорядочим данные: $40, 90, 110, 120, 125, 130, 135, 140, 150, 180$):
$$\frac{125 + 130}{2} = 127.5;$$
- **мода**: в наборе данных нет повторяющихся значений, поэтому мода не определена.

Компания B:

- **данные по зарплате** (в у.е.): $240, 120, 95, 105, 120, 100, 120, 120, 115, 90$;
- **количество значений**: 10;
- **среднее значение**:
$$\frac{240, 120, 95, 105, 120, 100, 120, 120, 115, 90}{10} = 122.5;$$
- **медиана** (упорядочим данные: $90, 95, 100, 105, 115, 120, 120, 120, 120, 240$):
$$\frac{115 + 120}{2} = 117.5;$$
- **мода**: наиболее часто встречающееся значение — 120 у.е. (встречается 4 раза).

Сделаем ***предварительные выводы***.

1. В компании A медиана значительно выше среднего ($127.5 > 122$). Это означает, что есть несколько сотрудников с зарплатой значительно ниже остальных (в нашем примере 40 и 90 у.е.), которые "тянут" среднее арифметическое вниз. Медиана лучше отражает типичную зарплату "среднего" сотрудника. Она показывает, что половина сотрудников в компании A получает меньше 127.5 у.е., а половина — больше.
2. В компании B медиана ниже среднего ($117.5 < 122.5$). Показатель средней зарплаты в 122.5 у.е. вводит в заблуждение. Он завышен из-за одной экстремально высокой зарплаты (наверное, руководителя) и не отражает реальный уровень доходов подавляющего большинства сотрудников. Уже на этом этапе анализа данных видна потенциальная аномалия — значение 240 сильно выделяется. Наиболее типичная зарплата в организации (мода) — 120 у.е. встречается 4 раза из 10, значит 40% сотрудников имеют одинаковую зарплату. Это очень важное наблюдение!

Оба набора данных показывают, что *среднее значение* в отрыве от *медианы* без визуализации распределения может быть глубоко вводящей в заблуждение метрикой.

При построении ***гистограммы*** распределения случайной величины данные группируются по определенным диапазонам и подсчитывается, сколько значений попадает в тот или иной диапазон. В результате будет нарисован набор столбиков (рис.), высота которых определяется числом случайных величин, попавших в тот или иной диапазон (или частотой их попадания в диапазон).

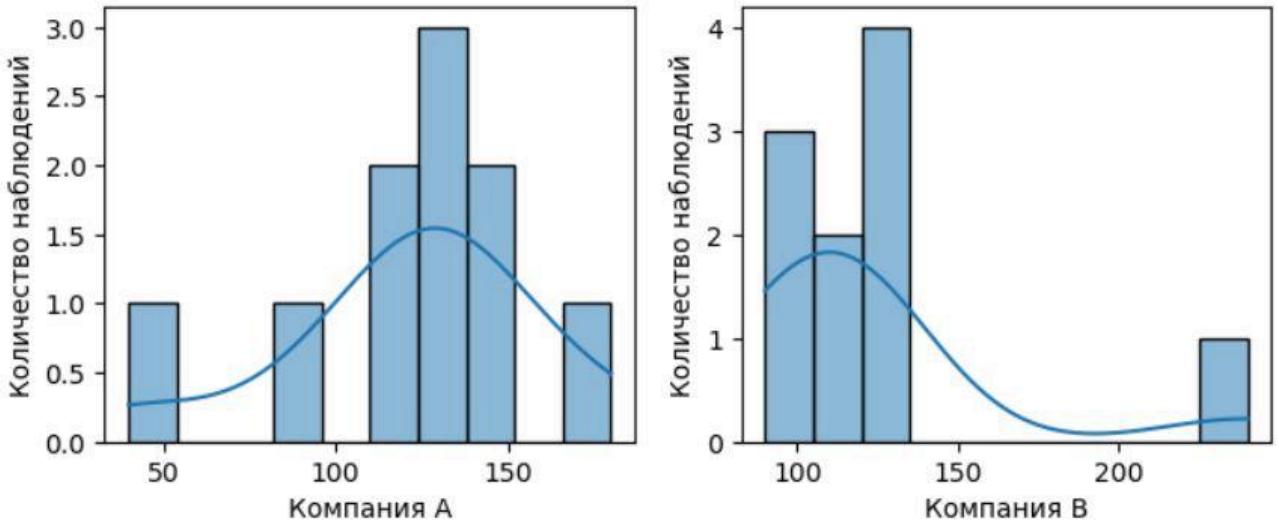


Рис. Гисторгаммы распеделения зарплат в компаниях A и B

Для сравнения рассматриваемых зарплат в компаниях A и B отобразим их с помощью *boxplot* (рис.)

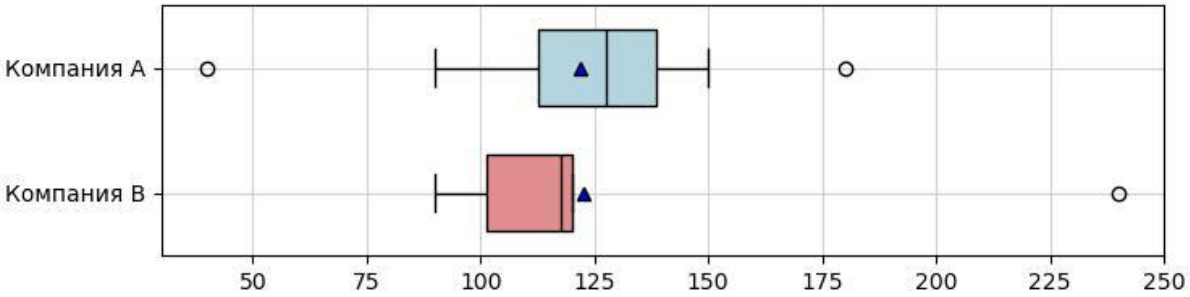


Рис. Визуализация распределений зарплат с помощью «ящика с усами»

2 Вероятности и статистика

При описании математики, лежащей в основе результатов, мы часто используем термины *вероятность* и *статистика*.

Разберемся в этих понятиях, чтобы по-настоящему осознать разницу между ними.

Представьте большой мешок со стеклянными шариками. Вы не знаете, какого они цвета. Вы не знаете ни их формы, ни размера. Вы даже не знаете, сколько их. Вы опускаете руку в мешок и вслепую берете горсть шариков.

Давайте остановимся на мгновение. У вас есть мешок, в который вы не заглядывали, и горсть стеклянных шариков в руке, которые вы никогда не видели. У вас нет никакой информации о том, что находится у вас в руке или в мешке.

И вот в чем разница. *Теория вероятности* позволяет вам угадать, что находится у вас в руке, если вам точно известно содержимое мешка. А *статистика* позволяет вам узнать о содержимом мешка на основании того, что оказалось у вас в руке.

Теория вероятности позволяет двигаться от общего к частному, то есть делать выводы о небольшом фрагменте данных на основе знаний о совокупности информации. А **математическя статистика** позволяет нам двигаться от частного к общему, то есть делать выводы о совокупности информации на основе доступных нам фрагментов

Критерий	Теория вероятностей	Математическая статистика
Что изучает	Изучает математические модели случайных явлений	Занимается сбором, анализом, интерпретацией и представлением данных
Ключевые объекты	Вероятность, случайные величины, распределения вероятностей	Выборка, оценка, проверка гипотез, доверительный интервал
Главный вопрос	"Что может произойти?" при условии, что мы знаем точные правила, по которым работает система	"Что произошло и что это значит?"
Исходные данные	Известная модель (распределение, параметры)	Эмпирические данные (выборка из реального мира)
Основной вопрос	"Каков шанс, что произойдет событие X?"	"Что данные говорят о мире?"
Направление вывода	От модели к данным	От данных к модели
Основная задача	Имея полное описание модели (например, "монета идеальная", "кость имеет 6 граней"), рассчитать вероятность того или иного события	Имея ограниченные данные (выборку) из реального мира, сделать вывод (инференцию) о свойствах всего мира (генеральной совокупности)
Пример	В идеальной модели монетка падает орлом и решкой с вероятностью $50\ \%$ ($P = 0.5$), найти вероятность выпадения 5 орлов подряд	Подбросив монету 100 раз и получив 60 орлов, проверить, что монетка идеальная

Теория вероятностей не спрашивает, подходит ли модель к реальности, а только **прогнозирует будущее на основе модели** (возможно, неверной).

Математическая статистика проверяет, насколько модель подходит к реальности, исходя из того насколько сильно идеальные прогнозы модели не соответствуют наблюдаемым реальным данным.

> **Теория вероятностей** – это математическая наука, изучающая закономерости случайных явлений.

> **Математическая статистика** – это математическая наука посвященная разработке методов описания и анализа статистических **экспериментальных** данных, полученных в результате наблюдений массовых случайных явлений.

3 Введение в теорию вероятностей

Вряд-ли кто сегодня скажет, что существуют случайные явления в мире или нет. Например, подбрасывая одну и ту же монетку в абсолютно одинаковых условиях и одинаковым образом, с точки зрения физики мы должны получать одно и то же ее положение: либо все время орел, либо все время решка.

Аналогично обстоит дело и с игральными кубиками: если бы каждый бросок можно было бы повторять совершенно одинаковым образом и в совершенно одинаковых условиях, то мы видели бы выпадение одной и той же его грани.



А вот привести пример события, которое бы менялось в экспериментах при одних и тех же исходных данных крайне затруднительно, если вообще возможно. Тогда про что же предмет «*Теория вероятностей*»?

Дело в том, что **многие явления удобнее представлять как случайные и, затем, использовать теорию вероятностей для анализа их поведения**.

Кроме того, исходные данные эксперимента часто невозможно точно измерить, так как физические приборы имеют (и всегда будут иметь) некоторые погрешности в своих измерениях. И эти маленькие погрешности впоследствии могут приводить к значительным изменениям.

> *Эффект бабочки* (Эдвард Лоренц, изчая погодные явления): взмах крыла бабочки в Техасе может впоследствии вызвать сильнейший ураган в Калифорнии.



> **Эффект бабочки** – метафора хаотической системы, где малые изменения порождают большие последствия.

Получается, что даже при отсутствии «настоящих» случайностей для нас, людей, многие явления кажутся случайными и именно так нам проще их воспринимать, описывать и анализировать. **Теория вероятностей как раз и предоставляет нам математический аппарат для «работы» с такими случайными явлениями**.

Что же такое вероятность?

Представьте, что вы играете в дартс и дротиками нужно попасть в центр мишени. Но делаете это с закрытыми глазами. При такой «слепой» игре, скорее всего, ваши дротики будут равномерно покрывать область стены вблизи мишени.

Смоделируем процесс метания дротиков, где площадь стены в два раза больше площади игрового круга.

Ввод [1]:
```
import matplotlib.pyplot as plt
from matplotlib.patches import Circle, Rectangle
import numpy as np
```

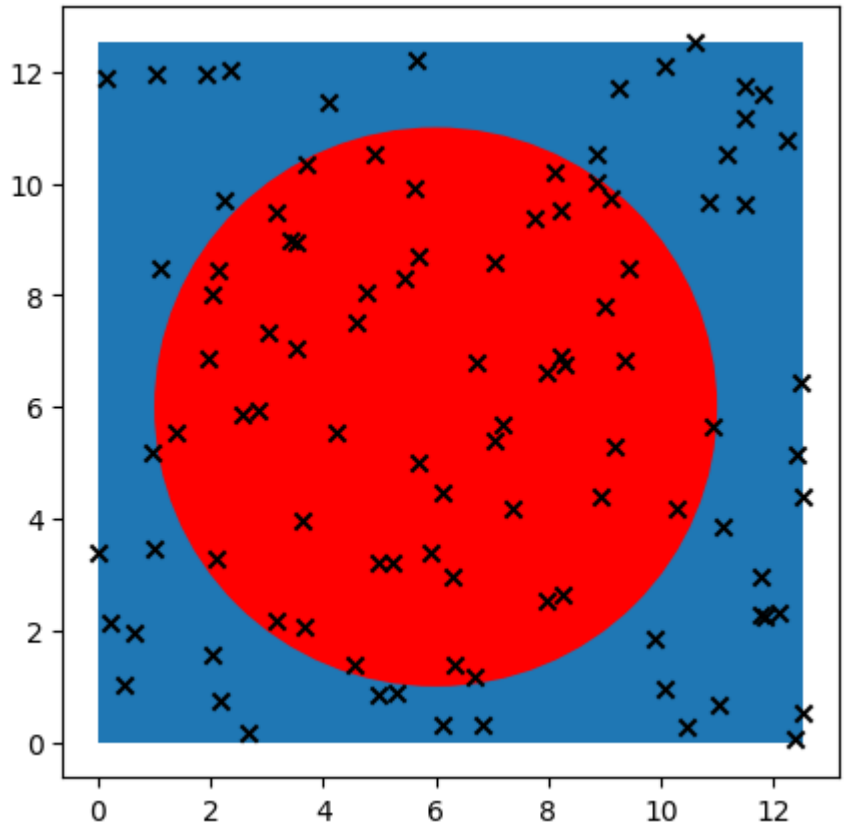
Ввод [2]:
```
def darts(size):
    x0, y0, R = 6, 6, 5
    side = np.sqrt(2 * np.pi * R ** 2)
    fig, ax = plt.subplots(figsize=(5, 5))
    ax = plt.gca()
    ax.add_patch(Rectangle((0, 0), side, side))
    ax.add_patch(Circle((x0, y0), R, facecolor='r'))

    X = np.random.uniform(0, side, size)
    Y = np.random.uniform(0, side, size)
    plt.scatter(X, Y, marker='x', c='black')

    inside = len([d for d in (X-x0)**2 + (Y - y0)**2 if d <= R**2])
    prob = inside / size

    plt.show()
    print(f'В красный круг из {size} дротиков попало {inside}. Доля попавших со
```

Ввод [4]:
```
darts(100)
```




```
В красный круг из 100 дротиков попало 54. Доля попавших составила 0.5400
```

Поскольку площадь квадрата в 2 раза больше площади круга, то ожидаемо, что **в среднем** доля попадания дротиков составит 0.5.

Что означает "в среднем"?

Дело в том, что бросание дротиков – это случайный процесс и вполне могут возникать ситуации, когда ни один из дротиков не попадет в мишень, или наоборот, все дротики попадут в мишень. Но даже при более-менее равномерном их распределении, доля попавших в мишень и не попавших, вряд ли составит величину 0.5. А вот если мы будем бесконечно долго бросать дротики, то сможем вплотную приблизиться к величине 0.5.

Поэтому, **когда говорят «в среднем», подразумевают предельный случай бесконечного числа экспериментов**.

Если мы в экспериментах сократим число дротиков до одного, то в среднем, все равно доля их попаданий в мишень будет равна 0.5. Получается, что **это число является некой объективной характеристикой случайного процесса**, а именно – случайного попадания дротиков в мишень размером в половину стены. По сути, оно означает, что в 50% случаях дротик попадает в цель, а в 50% не попадает. В теории вероятностей такое число называют вероятностью возникновения того или иного события (не обязательно случайного).

3.1 Основные определения

> **Случайный эксперимент (испытание)** – любая процедура с несколькими конечными результатами, повторимая конечное или бесконечное количество раз.

Пример. Подбрасывание игральной кости.

> Любой результат эксперимента ($\omega \in \Omega$) называется *элементарным исходом*.

Пример. При подбрасывании игральной кости выпало 5 очков.

> Множество всех возможных исходов эксперимента называют **пространством элементарных исходов**, обозначают Ω.

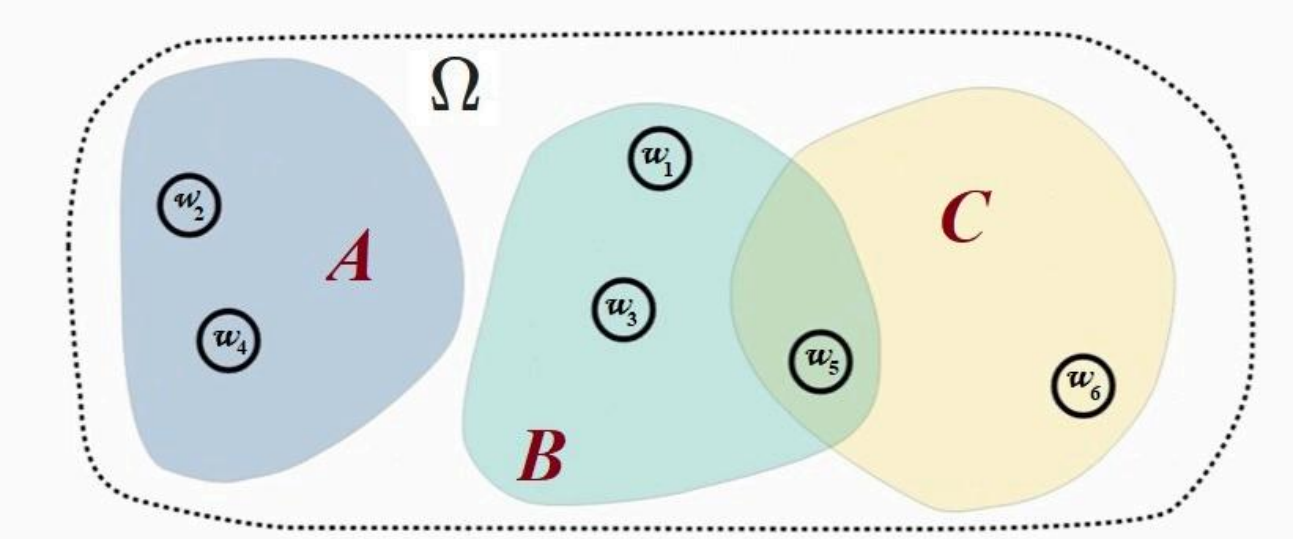
Пример. При подбрасывании игральной кости $\Omega = \{1, 2, 3, 4, 5, 6\}$.

> **Случайное событие** – любое подмножество исходов эксперимента, обозначают A, B, C, A_1 и т.д.

Пример случайных событий:

- A – при подбрасывании игральной кости выпало четное количество очков, меньшее 6: $A = \{2, 4\}$;
- B – при подбрасывании игральной кости выпало нечетное количество очков: $B = \{1, 3, 5\}$.

> Подмножество $A \subset \Omega$ назовем *произошедшим случайным событием*, если эксперимент закончился одним из элементарных исходов ω, входящих в множество A.



3.2 Виды событий

Два события A и B называются **несовместными**, если $A \bigcap B = \emptyset$.
Несовместные события в одном опыте не могут произойти одновременно.

Пример. На рисунке события A и C, A и B – несовместные.

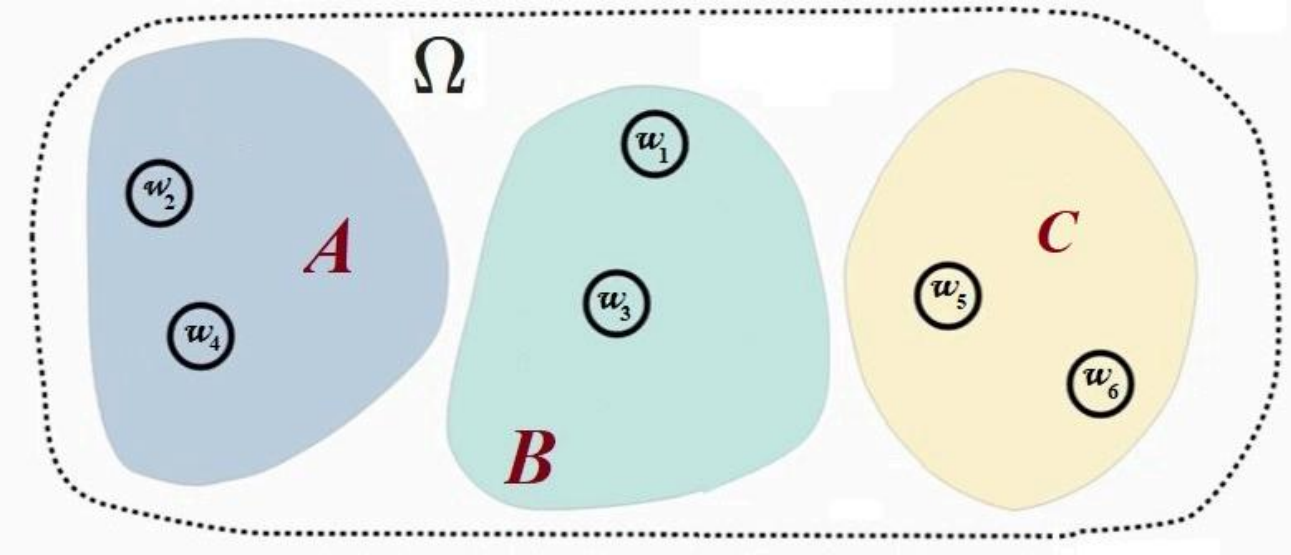
Два события A и B называются **совместными**, если $A \bigcap B \neq \emptyset$. Совместные события в одном опыте могут произойти одновременно.

Пример. На рисунке события B и C – совместные.

Два или более событий $A_1, A_2, \ldots$ **попарно несовместные**, если в опыте никакие два из них не могут произойти одновременно: $\forall i \neq j : A_i \bigcap A_j = \emptyset$.

Два или более событий **несовместные в совокупности**, если в опыте *все* они *не могут* произойти *одновременно*.

Если события $A_1, A_2, \ldots$ являются попарно несовместными и при этом $\bigcup_{i=1}^{\infty} A_i = \Omega$, то набор событий $A_1, A_2, \ldots$ формирует **разбиение пространства элементарных событий** Ω.



Полная группа событий – это совокупность событий, хотя бы одно из которых в опыте обязательно происходит.

Невозможное событие – это событие, которое в опыте никогда не происходёт. Обозначение $\emptyset$.

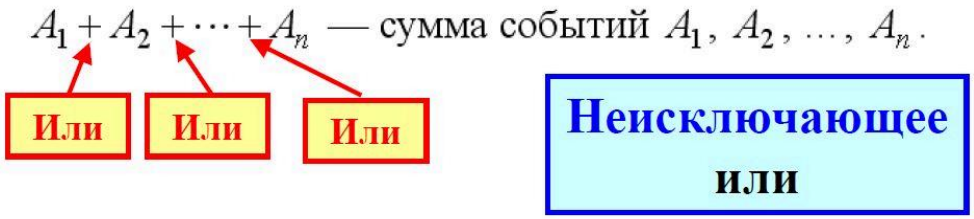
Пример. При подбрасывании одной игральной кости не может произойти событие *"выпало 13 очков"*.

Достоверное событие – это событие, которое в опыте происходит обязательно. Обозначение Ω.

Пример. При подбрасывании одной игральной событие *"выпало натуральной число очков, меньшее 7"*

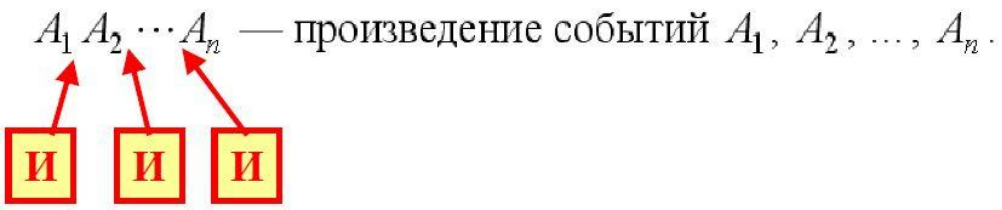
3.3 Действия над событиями

Сумма событий $A_1, A_2, \ldots, A_n$ – это событие, которое происходит, если в опыте происходит ***хотя бы одно*** из событий $A_1, A_2, \ldots, A_n$.



В теоретико-множественной трактовке сумму принято называть называть *объединением* $A \cup B$ – произошло либо A, либо B, либо A и B одновременно.

Произведение событий $A_1, A_2, \ldots, A_n$ – это событие, которое происходит, если в опыте ***одновременно*** происходят ***все*** события $A_1, A_2, \ldots, A_n$.



В теоретико-множественной трактовке произведение принято называть называть *пересечением* $A \cap B$ – произошли одновременно A и B.

> Событие A **влечет за собой** событие B (обозначается $A \Rightarrow B$ или $A \subset B$), означает, что если происходит событие A, то событие B обязательно происходит. Другими словами, появление события A гарантирует наступление события B. В этом случае множество элементарных исходов события A включено в множество элементарных исходов события B.

Пример. Пусть событие A – "выпало четное число очков на кубике", а событие B – "выпало число очков, не меньшее 2". В этом случае, если выпало четное число очков (событие A), то оно обязательно будет не меньшим 2 (событие B). Следовательно, событие A влечет за собой событие B.



3.4 Свойства вероятности

> Функция $P(A)$ называется **вероятностностной мерой** или **вероятностью** события A, если она принимает на вход событие A и возвращает значение от 0 до 1.

Если хотим посчитать, например, вероятность события A, обозначим $P(A)$ и получим число от 0 до 1. Можно провести аналогию между вероятностью и некоторой мерой (площадь, объём).

> **Вероятность** – это доля появлений случайного события в эксперименте. При этом предполагается, что эксперимент был проведен бесконечное число раз.

> Не всегда возможно провести эксперимент бесконечное число раз. Если количество экспериментов ограничивают, то полученную вероятность события A, называют **частотой события** A.

- $0 \leq P(A) \leq 1$;
- $P(\emptyset) = 0$;
- $P(\Omega) = 1$;
- $P(\overline{A}) = 1 - P(A)$;
- $P(A \bigcup B) = P(A) + P(B)$, если $A \bigcap B = \emptyset$.

3.5 Подходы к определению вероятности

3.5.1 Классический подход

Рассматривается конечное число исходов, считается, что все исходы равновероятны, вероятность события A определяется как отношение N_A – количества исходов, благоприятствующих событию A, к N – общему числу исходов:

$$P(A) = \frac{N_A}{N}$$

3.5.2 Частотный подход

При этом подходе вычисление вероятности построено на эксперименте, который проводится N раз ($N \to \infty$), а вероятность события A определяется как отношение N_A – количества исходов, когда событие A произошло, к N при $N \to \infty$:

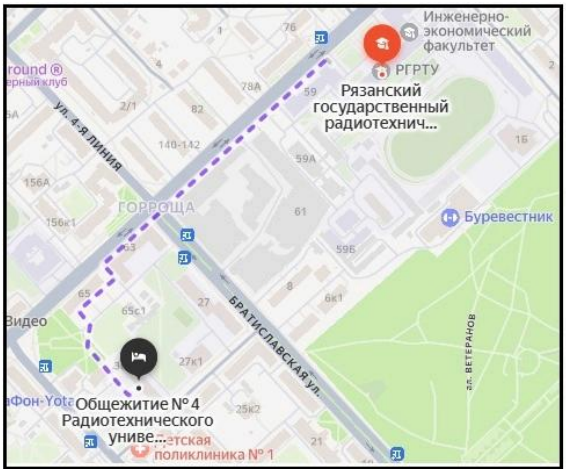
$$P(A) = \lim_{N \to \infty} \frac{N_A}{N}$$

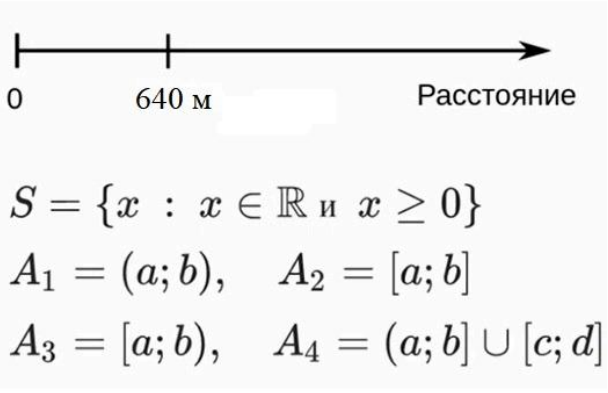
3.5.3 Байесовский подход

Каждому исходу задается ***априорная*** вероятность (до опыта), выражающая степень нашей веры в то, что этот исход произойдет, которая обновляется после эксперимента по формуле Байеса. Эта вероятность в бесконечном пределе сходится к реальной вероятности.

4 Аксиоматика Колмогорова

Рассмотрим пример определения расстояния (S) между двумя объектами. Какое значение мы ожидаем (каким может быть расстояние)?

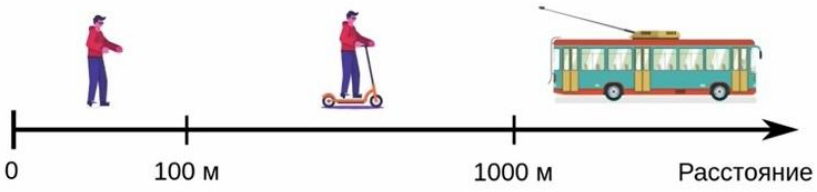




Про расстояние можно сказать, что:

1. Расстояние – это положительная часть вещественной оси $S = \{x : x \in \mathscr{R}, x \geq 0\}$, причем вероятность получить ∞ расстояние стремится к нулю.
2. Случайных событий (интервалов) можно привести много (см. рис.): A_1, A_2, A_3, A_4.

Рассмотрим пример выбора средства передвижения в зависимости от преодолеваемого расстояния. В этом примере **важно**, чтобы события выбора не пересекались.



$$A = [0; 100]$$
$$B = (100; 1000)$$
$$C = [1000; \infty)$$

В примере события A, B, C разбиение (они не пересекаются, а их объединение образуют все пространство элементарных событий.)

Аксиомы Колмогорова позволяют сделать переход от событий к вероятностям. ***Цель*** – описать вероятность как функцию меры (типа площади и объема). Только на вход подается пространство элементарных событий, а изверяем случайное событие, т.е. он стремился ***превратить пространство элементарных событий в измеримое пространство***.

Колмогоров при преводе вероятности на математический язык воспользовлся теорией мер (взял теорию мер и добавил очевидные свойства вероятности).

4.1 Немного из теории мер

> **Сигма-алгеброй** $\mathscr{F}$ называется набор подмножеств пространства Ω, если он удовлетворяет следующим аксиомам:

1. $\emptyset \in \mathscr{F}$.
2. $\mathscr{F}$ замкнуто относительно дополнения: $\mathrm{A} \in \mathscr{F} \Rightarrow \mathrm{A}^c \in \mathscr{F}$.
3. $\mathscr{F}$ замкнуто относительно счетного числа объединений: $A_1, A_2, \ldots \in \mathscr{F} \Rightarrow \bigcup\limits_{i=1}^{\infty} A_i \in \mathscr{F}$.

> Если **сигма-алгебра** $\mathscr{F}$ удовлетворяет аксиомам $1 - 3$, то пространство элементарных событий Ω, снабженное этой сигма-алгеброй $\mathscr{F}$ (т.е. пара $(\Omega, \mathscr{F})$) называется **измеримым пространством**.

В нашем случае Ω – пространство элементарных событий, $\mathscr{F}$ – набор случайных событий.

Рассмотрим построение сигма-алгебры на примере выбора средства передвижения в зависимости от преодолеваемого расстояния, где
$A = [0; 100]$, $B = (100; 1000)$, $C = [1000, \infty)$:

$$\mathscr{F} = \{\emptyset, A, B, C, (100; \infty), [0; 1000), [0; 100] \cup [1000; \infty)\}$$

4.2 Аксиомы Колмогорова

Пусть дано измеримое пространство $(\Omega, \mathscr{F})$, где Ω – пространство элементарных событий, и функция P, принимающая на вход элементы сигма-алгебры $\mathscr{F}$ и удовлетворяющая аксиомам:

Аксиома 1 (существование вероятности событий). Каждому событию $A \in \mathscr{F}$ поставлено в соответствие неотрицательное вещественное число $P(A)$ ($P(A) \in [0; \infty)$), которое называется вероятностью события A.

Аксиома 2 (нормировка вероятности). $P(\Omega) = 1$.

Аксиома 3 (аддитивность вероятности). Вероятность объединения попарно несовместных событий $A_1, A_2, \ldots \in \mathscr{F}$ равна сумме их вероятностей: $P(\bigcup\limits_{i=1}^{\infty} A_i) = \bigcup\limits_{i=1}^{\infty} P(A_i)$.

Если функция P удовлетворяет этим свойством, то тройка $(\Omega, \mathscr{F}, P)$ называется **вероятностным пространством**, а $P(A)$ называется **вероятностью события** $A \in \mathscr{F}$.

Замечание. *Аксиома 1* выражаетс свойство любой меры, она наклабывает на вероятность минимальное требование – быть не отрицательной величиной. *Аксиомы 2* и *Аксиома 3* приводят к тому, что $P(A) \in [0; 1]$.

5 Практика

5.1 Работа с датасетом сети ресторанов Chipotle

Ссылка для скачивания набора данных: https://www.kaggle.com/jeffreybraun/chipotle-locations (https://www.kaggle.com/jeffreybraun/chipotle-locations).

Chipotle – одна из самых популярных сетей мексиканских ресторанов быстрого питания в США.

Набор данных содержит записи с информацией по ресторанам сети *Chipotle* в Соединенных Штатах с полями:

- `state` – штат;
- `location` – местоположение (город);
- `address` – адрес;
- `latitude` – географическая широта (в градусах);
- `longitude` – географическая долгота (в градусах).

Определим вероятность выбора одного из средств предвижений (ногами, на самокате и на тролейбусе), рассчитав расстояние от случайной точки до ближайшего ресторана *Chipotle* в Нью-Йорке.