Практика. Условная вероятность. Теорема Байеса

Условная вероятность

Условная вероятность возникает в том случае, если мы хотим вычислить вероятность наступления некоторого события A при условии, что событие B уже наступило.

> **Условной вероятностью A при условии B**, причем $P(B) > 0$, называется $P(A|B) = \frac{P(AB)}{P(B)}$ ($P_B(A)$). Здесь $P(AB)$ – вероятность одновременного наступления событий A и B.

Часто для углубиления понимания условной вероятности рассматриваются различные ***парадоксы***.

> **Парадокс** – это утверждение, ситуация или рассуждение, которое противоречит общепринятому мнению, здравому смыслу или логике, но при этом может быть реальным, неоспоримым или иметь скрытую логику при более глубоком анализе.

Задачи-прадоксы с одной стороны, дают некоторый континтуитивный результат, а с другой они использовались для того, чтобы продвинуть теорию вероятностей вперед, они добавляли в нее то, чего не было раньше.

Зачастую спор о парадоксах связан с тем, что:

1. сама задача формулируется несколько неявно, поэтому возникают неоднозначные трактовки вероятностей, и, как следствие, получаются разные ответы;
2. человек, формулирующий задачу что-то недосказал.

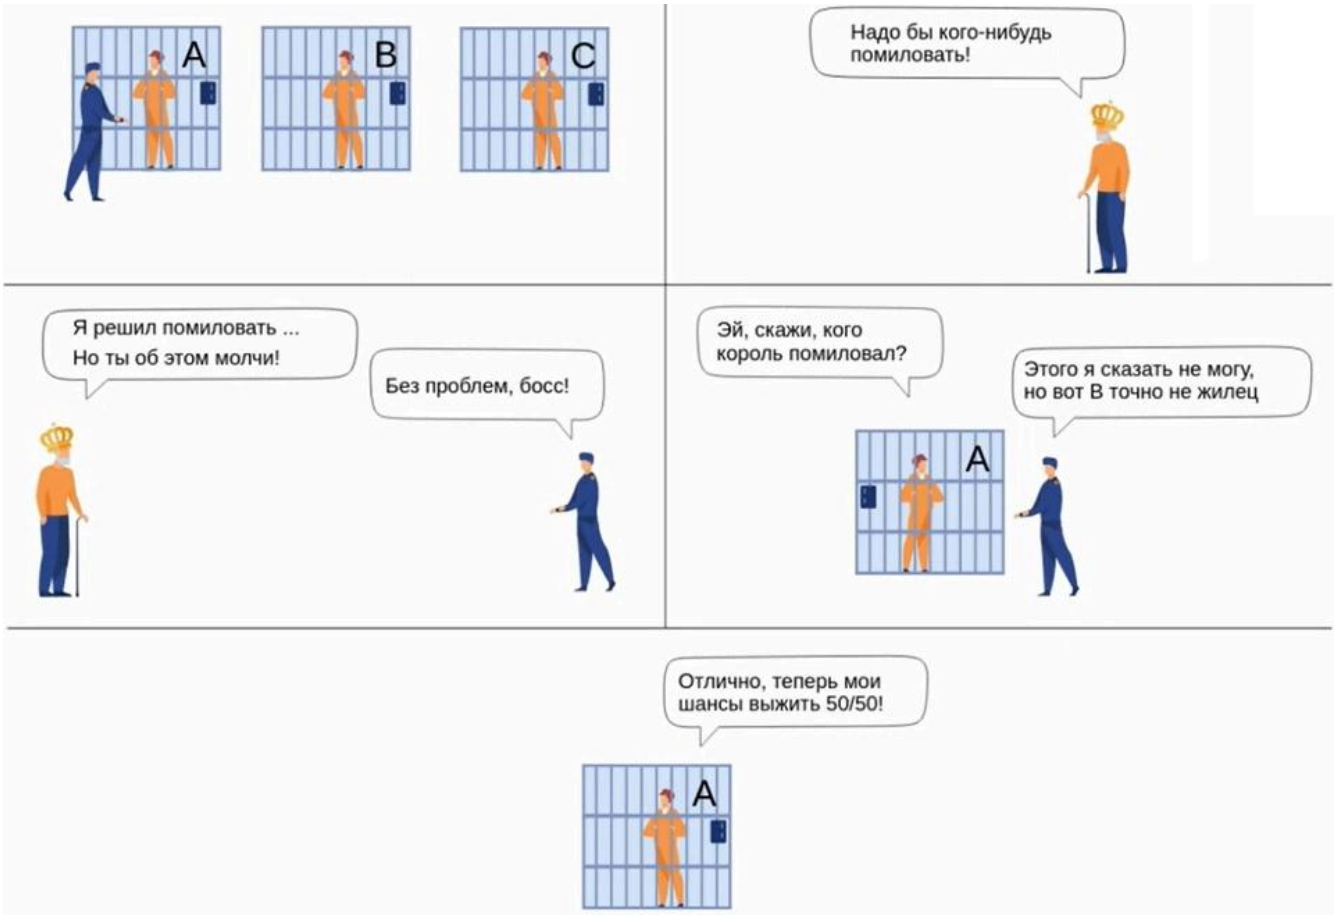
Задача о трех узниках

Есть три заключенных A, B, C. Все они приговорены к казни. Но король (а он очень добрый) решил кого-нибудь из них помиловать, и случайным образом выбирает одного узника. О своем решении он сообщает надзирателю, но просит, чтобы тот держал в секрете имя помилованного узника и не говорил заключенным об их судьбе. Прогуливаясь мимо камер, надзиратель услышал от узника A вопрос: "Скажи, кого король помиловал?".

– Я не могу тебе это сказать, но вот узник B будет казнен. – ответил надзиратель.

– Круто, теперь мои шансы выжить $50/50$, – сказал узник A.

Вопрос. Верно ли оценил ситуацию узник A? Или он слишком оптимистичен?



Рассмотрим события:

- A – помилован заключенный A;
- B – помилован заключенный B;
- C – помилован заключенный C;
- W – надзиратель сказал, что казнен будет заключенный B.

Вероятности помилования у каждого заключенного $\frac{1}{3}$ (король делает случайный выбор):

$$P(A) = P(B) = P(C) = \frac{1}{3}$$

Требуется **вычислить вероятность того, что помилован A, если надзиратель сказал, что казнен будет B** (и сравнить с 0.5):

$$P(A|W) = ?$$

Распишем эту формулу по определению условной вероятности:

$$P(A|W) = \frac{P(A) \cdot P(W)}{P(W)} = \frac{P(A) \cdot P(W)}{P(W \cdot \Omega)} = \frac{P(A) \cdot P(W)}{P(W \cdot A) + P(W \cdot B) + P(W \cdot C)}$$

Т.к. $(A + B + C = \Omega)$

Распишем отдельно вероятности в знаменателе:

$$P(W \cdot A) = P(A \cdot W) = P(A) \cdot P(W|A) = \frac{1}{3} \cdot \frac{1}{2} = \frac{1}{6}$$

Здесь $P(W|A)$ – вероятность того, что надзиратель сказал, что казнен будет B, при условии, что помилован будет A. Надзиратель не может сказать A, что он помилован (это будет нарушением слова, данного королю). Остается выбор между B и C, и надзиратель делает этот выбор случайным образом, значит $P(W|A) = \frac{1}{2}$.

$$P(W \cdot B) = P(B \cdot W) = P(B) \cdot P(W|B) = \frac{1}{3} \cdot 0 = 0$$

Здесь $P(W|B)$ – вероятность того, что надзиратель сказал, что казнен будет B, при условии, что помилован будет B. Надзиратель не врет заключенному и так сказать он не может, поэтому $P(W|B) = 0$.

$$P(W \cdot C) = P(C \cdot W) = P(C) \cdot P(W|C) = \frac{1}{3} \cdot 1 = \frac{1}{3}$$

Здесь $P(W|C)$ – вероятность того, что надзиратель сказал, что казнен будет B, при условии, что помилован будет C. Надзиратель не может сказать A, что помилован будет C (это будет нарушением слова, данного королю). Остается выбор между B и A, но он не может сказать узнику A о его судьбе (он обещал королю), значит ему остается только сказать, что B будет казнен $P(W|C) = 1$.

Подставив в формулу выше, получим:

Формула полной вероятности

> ***Теорема (формула полной вероятности)***. Если событие A может произойти только при условии появления одного из событий (гипотез) $\{H_1, H_2, .., H_n\}$, образующих ***полную группу***, то вероятность события A равна сумме произведений вероятностей каждого из этих событий (гипотез) на соответствующие условные вероятности события A:

$$P(A) = \sum_{i=1}^{n} P(H_i) \cdot P(A|H_i)$$

Формула Байеса

> ***Теорема (формула Байеса)***. Формулу Байеса в простейшем варианте для двух случайных событий A и B, можно записать в виде:

$$P(A|B) = \frac{P(A) \cdot P(B|A)}{P(B)}, P(B) > 0$$

Заметим, что если использовать формулу полной вероятности, то можно записать формулу Байеса в виде:

$$P(H_i|A) = \frac{P(H_i) \cdot P(A|H_i)}{\sum_{i=1}^{n} P(H_i) \cdot P(A|H_i)}$$

Задача (страшный диагноз)

Предположим, что некий тест на какую-нибудь страшную болезнь с вероятностью $0,95$ (то есть, в 95 % случаях) не ошибается (дает верные результаты). Также известно, что этой болезнью страдает, в среднем, 1% населения (вероятность $0,01$). Некий человек (совершенно случайный) получает положительный результат данного теста. Вопрос. С какой вероятностью он действительно болен?



И введем следующие события:

- Б – случайный человек болен;
- П – тест показал положительный результат.

Нам нужно найти вероятность, что человек болен, при условии получения им положительного результата теста, то есть, условную вероятность:

$$P(\text{Б}|\text{П}) = ?$$

В соответствии с формулой Байеса, эта вероятность определяется, как:

$$P(\text{Б}|\text{П}) = \frac{P(\text{Б}) \cdot P(\text{П}|\text{Б})}{P(\text{П})}$$

Подставим исходные данные в формулу Байеса и получим вероятность того, что человек действительно болен при положительном результате теста:

$$P(\text{Б}|\text{П}) = \frac{0.01 \cdot 0.95}{0.01 \cdot 0.95 + 0.99 \cdot 0.05} = 0.16$$

Получили, что у человека есть неплохой шанс оказаться на самом деле здоровым.

Вот это показательный пример того, как формула Байеса нам помогает верно найти вероятность

Задача (про кредит)

Задача. Жители некоторых трех районов приходят в банк и хотят взять кредит. Жители первого района приходят с частотой 0.6, второго – 0.3, а третьего – с частотой 0.1. Вероятность того, что жителю первого района одобрят кредит равна 0.4, что жителю второго – 0.9, что третьего – 0.2. Известно, что последнему жителю одобрили кредит. С какой условной вероятностью это был житель третьего района?

Введем обозначения:

- A – *последнему жителю одобрили кредит*,
- H_1 – *последний клиент был из первого района*;
- H_2 – *последний клиент был из второго района*;
- H_3 – *последний клиент был из третьего района*.

Теперь разберемся, как следует записать события через вероятность:

$$P(H_1) = 0.6, P(H_2) = 0.3, P(H_3) = 0.1, P(A|H_1) = 0.4, P(A|H_2) = 0.9, P(A|H_3) = 0.2$$

Хотим найти

$$P(H_3|A) = \frac{P(H_3) \cdot P(A|H_3)}{P(A)} = \frac{P(H_3) \cdot P(A|H_3)}{P(H_1) \cdot P(A|H_1) + P(H_2) \cdot P(A|H_2) + P(H_3) \cdot P(A|H_3)} = \frac{0}{}$$

Решение задач

Задача 1.72

Страховая компания разделяет застрахованных по классам риска: I класс – малый риск, II класс – средний, III класс – большой риск. Среди этих клиентов 50% – первого класса риска, 30% – второго и 20% – третьего. Вероятность необходимости выплачивать страховое вознаграждение для первого класса риска равна $0,01$, второго – $0,03$, третьего – $0,08$. Какова вероятность того, что:

- застрахованный получит денежное вознаграждение за период страхования;
- получивший денежное вознаграждение застрахованный относится к группе малого риска?

Задача 1.76

Вероятность изготовления изделия с браком на данном предприятии равна $0,04$. Перед выпуском изделие подвергается упрощенной проверке, которая в случае бездефектного изделия пропускает его с вероятностью $0,96$, а в случае изделия с дефектом – с вероятностью $0,05$. Определить:

- какая часть изготовленных изделий выходит с предприятия;
- какова вероятность того, что изделие, выдержавшее упрощенную проверку, бракованное?

Задача 1.77

В одной урне 5 белых и 6 черных шаров, а в другой – 4 белых и 8 черных шаров. Из первой урны случайным образом вынимают 3 шара и опускают во вторую урну. После этого из второй урны также случайно вынимают 4 шара. Найти вероятность того, что все шары, вынутые из второй урны, белые.

Задача 1.78

Из n экзаменационных билетов студент A подготовил только m ($m < n$). В каком случае вероятность вытащить на экзамене «*хороший*» для него билет выше: когда он берет наудачу билет первым, или вторым, ..., или k-м ($k < n$) по счету среди сдающих экзамен?

Следует добавить, что экзамен проходит по следующей схеме: если некоторый билет уже был вытянут, то после ответа экзаменатор откладывает его в сторону.

Ввод [274]:
```
from sympy import symbols, simplify
```

Ввод [275]:
```
m, n = symbols('m n')
```

Студент **берет билет вторым**. Вероятность вытащить *хороший* билет равна:

Ввод [276]:
```
simplify(m / n * (m - 1) / (n - 1) + (n - m) / n * m / (n - 1))
```

Out[276]: $\frac{m}{n}$

Студент **берет билет третьим**. Вероятность вытащить *хороший* билет равна:

Ввод [278]:
```
simplify(m / n * (m - 1) / (n - 1) * (m - 2) / (n - 2) +      # GGG
         m / n * (n - m) / (n - 1) * (m - 1) / (n - 2) +      # GBG
         (n - m) / n * m / (n - 1) * (m - 1) / (n - 2) +      # BGG
         (n - m) / n * (n - m - 1) / (n - 1) * m / (n - 2)    # BBG
        )
```

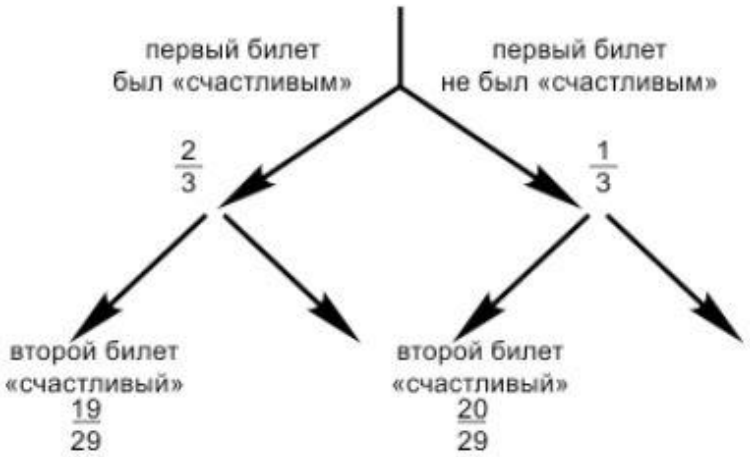
Out[278]: $\frac{m}{n}$

Студент **берет билет четвертым**. Вероятность вытащить *хороший* билет равна:

Ввод [279]:
```
simplify(m / n * (m - 1) / (n - 1) * (m - 2) / (n - 2) * (m - 3) / (n - 3) +
         (n - m) / n * m / (n - 1) * (m - 1) / (n - 2) * (m - 2) / (n - 3) +
         m / n * (n - m) / (n - 1) * (m - 1) / (n - 2) * (m - 2) / (n - 3) +
         m / n * (m - 1) / (n - 1) * (n - m) / (n - 2) * (m - 2) / (n - 3) +
         (n - m) / n * (n - m - 1) / (n - 1) * m / (n - 2) * (m - 1) / (n - 3) +
         m / n * (n - m) / (n - 1) * (n - m - 1) / (n - 2) * (m - 1) / (n - 3) +
         (n - m) / n * m / (n - 1) * (n - m - 1) / (n - 2) * (m - 1) / (n - 3) +
         (n - m) / n * (n - m - 1) / (n - 1) * (n - m - 2) / (n - 2) * m / (n - 3)
        )
```

Out[279]: $\frac{m}{n}$

Пусть студент выучил 20 билетов из 30. Когда ему выгоднее идти, первым или вторым, чтобы вероятность вынуть выученный билет была больше?



Ввод [281]:
```
from random import shuffle
```

Студент **берет билет k-ым**. Вероятность вытащить *хороший* билет равна:

Ввод [286]:

```
k = 2
m = 20
n = 30
N = 100_000

student = list(range(1, m + 1))
tickets = list(range(1, n + 1))
result = []

for _ in range(N):
  shuffle(tickets)
  result.append(tickets[k - 1] in student)

np.mean(result)
```

Out[286]: np.float64(0.66699)

Применение условных вероятностей в анализе данных

Ввод [1]:

```
import numpy as np
import pandas as pd
```

Ввод [2]:

```
data = pd.read_csv("Data/data.csv")
data
```

Out[2]:

	company	model	rating	type
0	ford	mustang	A	coupe
1	chevy	camaro	B	coupe
2	ford	fiesta	C	sedan
3	ford	focus	A	sedan
4	ford	taurus	B	sedan
5	toyota	camry	B	sedan

Ввод [3]:

```
# Уникальные значения для признака  'rating'
data['rating'].unique()
```

Out[3]: array(['A', 'B', 'C'], dtype=object)

Ввод [4]:

```
# Уникальные значения для признака  'type'
data['type'].unique()
```

Out[4]: array(['coupe', 'sedan'], dtype=object)

Посчитаем вероятности для $P(rating)$

$$P(A) = \frac{2}{6} = 0.3333, \quad P(B) = \frac{3}{6} = 0.5, \quad P(C) = \frac{1}{6} = 0.1667$$

Ввод [5]:
```
rating_probs = data.groupby('rating').size().div(len(data))
rating_probs
```

Out[5]:
```
rating
A    0.333333
B    0.500000
C    0.166667
dtype: float64
```

Немного перегруппируем таблицу

Ввод [6]:
```
data['count'] = 1
pivot = pd.pivot_table(
    data,
    values='count',
    index=['rating'],
    columns=['type'],
    aggfunc=np.size,
    fill_value=0
)
pivot
```

Out[6]:

rating	coupe	sedan
A	1	1
B	1	2
C	0	1

Посчитаем все условные вероятности для $P(type|rating)$

$$P(coupe|A) = \frac{P(coupe \cdot A)}{P(A)} = \frac{\frac{1}{6}}{0.3333} = 0.5;\ P(coupe|B) = \frac{P(coupe \cdot B)}{P(B)} = \frac{\frac{1}{6}}{0.5} = 0.3333;$$

$$P(sedan|A) = \frac{P(sedan \cdot A)}{P(A)} = \frac{\frac{1}{6}}{0.3333} = 0.5;\ P(sedan|B) = \frac{P(sedan \cdot B)}{P(B)} = \frac{\frac{2}{6}}{0.5} = 0.6667;\ P($$

Сгруппируем машины по типу кузова (*купе* или *седан*) в зависимости от рейтинга (*A*, *B*, *C*)

Ввод [7]:
```
data.groupby(['type', 'rating']).size().div(len(data)).div(rating_probs, axis=0, l
```

Out[7]:
```
type   rating
coupe  A         0.500000
       B         0.333333
sedan  A         0.500000
       B         0.666667
       C         1.000000
dtype: float64
```

Посчитаем вероятности для $P(type)$

$$P(coupe) = \frac{2}{6} = 0.3333,\quad P(sedan) = \frac{4}{6} = 0.6667$$

Ввод [8]:
```
type_probs = data.groupby('type').size().div(len(data))
type_probs
```

Out[8]:
```
type
coupe    0.333333
sedan    0.666667
dtype: float64
```

Немного перегруппируем таблицу

Ввод [9]:
```
pivot = pd.pivot_table(
    data,
    values='count',
    index=['type'],
    columns=['rating'],
    aggfunc=np.size,
    fill_value=0
)
pivot
```

Out[9]:

type	rating A	B	C
coupe	1	1	0
sedan	1	2	1

Посчитаем все условные вероятности для $P(rating|type)$

$$P(A|coupe) = \frac{P(A \cdot coupe)}{P(coupe)} = \frac{\frac{1}{6}}{0.3333} = 0.5;\ P(A|sedan) = \frac{P(A \cdot sedan)}{P(sedan)} = \frac{\frac{1}{6}}{0.6667} = 0.25$$

$$P(B|coupe) = \frac{P(B \cdot coupe)}{P(coupe)} = \frac{\frac{1}{6}}{0.3333} = 0.5;\ P(B|sedan) = \frac{P(B \cdot sedan)}{P(sedan)} = \frac{\frac{2}{6}}{0.6667} = 0.5$$

$$P(C|coupe) = \frac{P(C \cdot coupe)}{P(coupe)} = \frac{\frac{0}{6}}{0.3333} = 0;\ P(C|sedan) = \frac{P(A \cdot sedan)}{P(sedan)} = \frac{\frac{1}{6}}{0.6667} = 0.25$$

Сгруппируем машины по рейтингу (*A*, *B*, *C*) в зависимости от типа кузова (*купе* или *седан*)

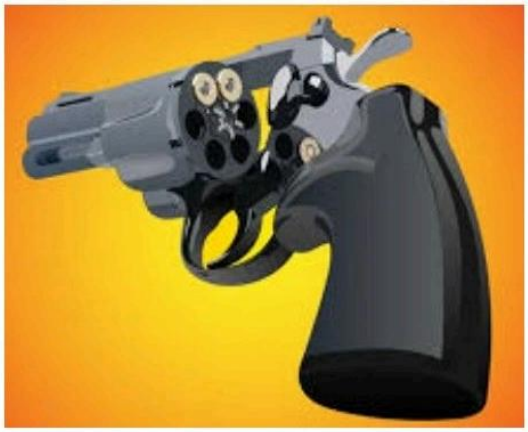
Ввод [10]:
```
data.groupby(['rating', 'type']).size().div(len(data)).div(type_probs, axis=0, lev
```

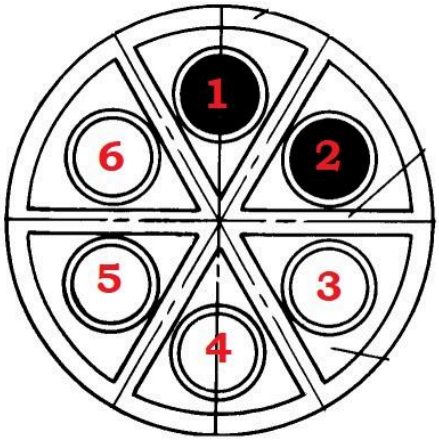
Out[10]:
```
rating  type
A       coupe    0.50
        sedan    0.25
B       coupe    0.50
        sedan    0.50
C       sedan    0.25
dtype: float64
```

Русская рулетка: нажать на курок или вращать барабан

Задача (на условную вероятность). Двое мужчин играют в русскую рулетку. В револьвере два патрона находятся в двух соседних патронниках.

Первый крутанул барабан, нажал на курок, и всё в порядке – остался жив (значит, патронник был пуст). Теперь очередь второго. Ему можно покрутить барабан перед выстрелом. Что должен сделать второй человек: нажать на курок или крутануть барабан?





Ответ: нажать на курок.

Объяснение:

Если человек вращает барабан, то 2 патронника с пулей, а 4 пусты. Вероятность "вытащить" пустой патронник равна $\frac{4}{6} = \frac{2}{3}$.

Пусть патроны в ячейках 1 и 2. Тогда перед первым выстрелом мушка была напротив ячейки 3, 4, 5, 6.

Важно: револьвер после щелчка остается в положении, когда следующий патронник готов к выстрелу. То есть если сейчас был пустой в позиции k, то следующий патронник – $k + 1 (mod 6)$.

Если второй НЕ крутит барабан (стреляет сразу)

Следующий патронник после первого выстрела:

- если первый выстрел из 3 патронника, то следующий – 4 (пустой) → второй игрок жив.
- если первый выстрел из 4 патронника, то следующий – 5 (пустой) → жив.
- если первый выстрел из 5 патронника, то следующий – 6 (пустой) → жив.
- если первый выстрел из 6 патронника, то следующий – 1 (патрон) → умер.

Вероятность смерти только в одном случае из четырех → $\frac{1}{4}$.

$$P(\text{смерть} | \text{некрутит}) = \frac{1}{4}$$

Если второй крутит барабан

Крутит → случайная из 6 позиций, 2 с патронами.

$$P(\text{смерть} | \text{крутит}) = 2/6 = 1/3$$

Вывод: Второму человеку не следует крутить барабан, вероятность выстрела в этом случае меньше (25% против 33%).

Ввод [26]:

```
import numpy as np
import pandas as pd
```

Ввод [14]:
```
chamber = [1, 1, 0, 0, 0, 0]
```

Ввод [215]:
```
# Один поворот патронника по часовой стрелке (сдвиг вправо)
def one_turn(chamber):
    n = len(chamber)
    new_chamber = [chamber[n - 1]] + chamber[:n - 1]
    return new_chamber
```

Ввод [216]:
```
one_turn([1, 0, 0, 0, 0, 1])  # проверка для одного поворота
```

Out[216]:
```
[1, 1, 0, 0, 0, 0]
```

Ввод [217]:
```
# Случайное вращение патронника
def spin_chamber(chamber):
    n = np.random.randint(1, 7)
    for _ in range(n):
        chamber = one_turn(chamber)
    return chamber
```

Ввод [218]:
```
spin_chamber([1, 1, 0, 0, 0, 0]) # проверка случайного вращения
```

Out[218]:
```
[0, 0, 1, 1, 0, 0]
```

Ввод [219]:
```
# Смоделируем 100_000 случайных вращений патронника
pd.Series([spin_chamber([1, 1, 0, 0, 0, 0]) for _ in range(100_000)]).astype(str).
```

Out[219]:
```
[0, 0, 0, 1, 1, 0]    0.16806
[1, 0, 0, 0, 0, 1]    0.16775
[0, 1, 1, 0, 0, 0]    0.16677
[0, 0, 1, 1, 0, 0]    0.16625
[0, 0, 0, 0, 1, 1]    0.16599
[1, 1, 0, 0, 0, 0]    0.16518
Name: proportion, dtype: float64
```

Посмотрим исход в случае, когда игроки делают **по одному выстрелу** и **второй перед выстрелом крутит барабан**:

Ввод [263]:
```
chamber = [1, 1, 0, 0, 0, 0]      # заряжаем револьвер

chamber = spin_chamber(chamber)   # первый игрок крутит барабан
p1 = chamber[0]                   # результат нажатия на курок для первого
chamber[0] = 0                    # убрали пулю после выстрела
chamber = one_turn(chamber)       # после выстрела барабан прокрутился

chamber = spin_chamber(chamber)   # второй игрок вращает барабан - нужно ли это де
p2 = chamber[0]                   # результат нажатия на курок для второго
chamber[0] = 0                    # убрали пулю после выстрела
chamber = one_turn(chamber)       # после выстрела барабан прокрутился
```

Ввод [264]:
```
p1, p2
```

Out[264]:
```
(0, 0)
```

Смоделируем русскую рулетку, когда второй игрок перед выстрелом **крутит** барабан

Ввод [265]:

```
n = 100_000
result = []

for _ in range(n):
    chamber = [1, 1, 0, 0, 0, 0]      # заряжаем револьвер

    chamber = spin_chamber(chamber)   # первый игрок крутит барабан
    p1 = chamber[0]                   # результат нажатия на курок для первого
    chamber[0] = 0                    # убрали пулю после выстрела
    chamber = one_turn(chamber)       # после выстрела барабан прокрутился

    chamber = spin_chamber(chamber)   # второй игрок вращает барабан - нужно ли эт
    p2 = chamber[0]                   # результат нажатия на курок для второго
    chamber[0] = 0                    # убрали пулю после выстрела
    chamber = one_turn(chamber)       # после выстрела барабан прокрутился

    result.append((p1, p2))
```

Ввод [267]:

```
df = pd.DataFrame(result, columns=['p1','p2'])
df.sample(10)
```

Out[267]:

	p1	p2
21573	1	1
69036	1	0
54014	0	0
11938	0	0
98225	1	0
82853	1	0
63619	1	0
22826	0	1
9401	1	0
81947	0	0

Ввод [268]:

```
df.groupby('p1')['p2'].agg(['count','mean'])
```

Out[268]:

	count	mean
p1		
0	66796	0.333837
1	33204	0.166456

Вывод: если первый игрок выжил (`p1=0`), то если второй игрок будет крутить барабан, то вероятность его гибели равна 33%.

Смоделируем русскую рулетку, когда второй игрок перед выстрелом **НЕ крутит** барабан

Ввод [269]:

```
n = 100_000
result = []

for _ in range(n):
    chamber = [1, 1, 0, 0, 0, 0]      # заряжаем револьвер

    chamber = spin_chamber(chamber)   # первый игрок крутит барабан
    p1 = chamber[0]                   # результат нажатия на курок для первого
    chamber[0] = 0                    # убрали пулю после выстрела
    chamber = one_turn(chamber)       # после выстрела барабан прокрутился

    # второй игрок не вращает барабан
    p2 = chamber[0]                   # результат нажатия на курок для второго
    chamber[0] = 0                    # убрали пулю после выстрела
    chamber = one_turn(chamber)       # после выстрела барабан прокрутился

    result.append((p1, p2))
```

Ввод [272]:

```
df = pd.DataFrame(result, columns=['p1','p2'])
df.groupby('p1')['p2'].agg(['count','mean'])
```

Out[272]:

p1	count	mean
0	66645	0.253627
1	33355	0.494049

Вывод: если первый игрок выжил (`p1=0`), то если второй игрок не будет крутить барабан, то вероятность его гибели равна 25%.

Выгоднее не вращать барабан!

Домашняя работа

Самостоятельно надо:

- разобрать решение задач $\S 1.11$ в учебнике Кремера;
- решить $1.73, 1.74, 1.75, 1.79$;
- Решить классически и смоделировать решение задачи. В одной урне 15 белых и 5 черных шаров, а в другой – 6 белых и 1 черный шар. Из первой урны случайным образом вынимают 3 шара и опускают во вторую урну. После этого из второй урны также случайно вынимают 1 шар. Найти вероятность того, что шар, вынутый из второй урны – белый.

Ввод [ ]: